


GPU-Server für KI-Selfhosting: Hetzner GEX44 im Test

| 15.07.2026 07:30 Uhr Jan Mahn



Lokale KI-Modelle können eine Alternative zu KI-Abos sein. Wer teure GPUs nicht kaufen will, kann sie mieten: Wir haben den GEX44 von Hetzner getestet.

Video-RAM, Video-RAM und noch mal Video-RAM: Das ist die wichtigste Zutat für einen Server, der große Sprachmodelle (LLMs) ausführen soll. Nur wenn die Modelle komplett in den schnellen Speicher der Grafikkarte (VRAM) passen, können die Modelle fix antworten. Doch wer aktuell darüber nachdenkt, LLMs selbst zu hosten, um den großen KI-Anbietern zu entkommen, ist mit extrem hohen Kosten für Grafikkarten mit viel Speicher konfrontiert, auch weil der Markt von ebendiesen großen KI-Anbietern leergekauft wird. Gemietete Server bei kleineren Hostern mit leistungsstarker GPU sind eine Alternative, um die hohen Anfangsinvestitionen zu vermeiden und Erfahrungen mit dem KI-Selfhosting zu sammeln.

Der deutsche Hoster **Hetzner** hat zwei Server mit starker GPU [1] im Sortiment. Für 1500 Euro monatlich gibt es den GEX131 mit einer **Nvidia RTX Pro 6000 Blackwell Max-Q** [2] darin (mit 96 GByte VRAM und ab 256 GByte RAM). Der kleine Bruder des Servers heißt GEX44. Für 278 Euro im Monat bekommt man dort die **Nvidia RTX 4000 SFF Ada Generation** [3] (mit 20 GByte VRAM und 64

GByte RAM). Angeboten wird die Konfiguration, um KI-Modelle zu betreiben (der große Bruder wird für KI-Training beworben). Mit Preis und Ausstattung richtet sich Hetzner mit dem GEX44 an Firmen, die lokale KI ausprobieren wollen.

MEHR ZU HARDWARE FÜR LOKALE KI-MODELLE

[GPU-Server für KI-Selfhosting: Hetzner GEX44 im Test \[4\]](#)

[Sprachmodelle mit Open WebUI: LLM-Server für kleine Teams selbst hosten \[5\]](#)

[Kompakte KI-Workstation: Gigabyte AI Top Atom alias Nvidia DGX Spark im Test \[6\]](#)

[Framework Desktop im Test: Das KI-Monster? \[7\]](#)

[Lokale KI-Modelle sind jetzt brauchbar \(und auf dieser Hardware laufen sie\) \[8\]](#)

[Sprachmodelle lokal betreiben: Fünf Tools vorgestellt \[9\]](#)

[Übersicht über kleine KI-Modelle, die sich für den lokalen Betrieb eignen \[10\]](#)

[HP Z2 Mini G1a: Kompakte Workstation mit starkem Kombiprozessor im Test \[11\]](#)

[Apple Mac mini mit M4 und M4 Pro im Test \[12\]](#)

[Mac Studio M3 Ultra: Apples schnellster Mehrkerner im Test \[13\]](#)

Wir haben den Server einen Monat lang intensiv beschäftigt und darauf eine **Containerzusammenstellung mit Open WebUI und Ollama [14]** betrieben. Mit dieser Kombination kann ein kleines Team in einer komfortablen Weboberfläche gemeinsam **Open-Weights- und Open-Source-Modelle [15]** nutzen.

PRODUKTDDETAILS

GEX44

BESCHREIBUNG

Erlebe mit dem neuen Dedicated Server GEX44 beeindruckende Performance dank der Rechenkraft des GPU-Computings. GPUs sind aufgrund ihrer Prozessorarchitektur für die Durchführung von parallelisierten Prozessen ausgelegt, um so große oder komplexe Datenmengen besonders schnell und effizient zu verarbeiten. Der neue GPU-Server GEX44 nutzt dafür die leistungsstarke NVIDIA RTX™ 4000 SFF Ada-Generation-Grafikkarte mit 20 GB GDDR6 ECC Grafikspeicher und bietet so vielfältige Möglichkeiten rund um Künstliche Intelligenz zum besten Preis. Ein Intel® Core™ i5-13500 Prozessor der 13. Generation "Raptor Lake" mit Hyper-Threading Technology Virtualization (Intel-VT) und stolzen 6 Performance- und 8 Effizienz-Kernen sowie 64 GB DDR4 RAM und zwei schnellen 1.92 TB Gen3 NVMe SSDs der Datacenter Edition machen den GEX44 zu einem innovativen Kraftpaket.

VERFÜGBARE SYSTEME

Ubuntu Linux Cent OS Windows

 Alle Betriebssysteme in 64 Bit.

INTEL® CORE™ I5-13500
incl. Hyper-Threading Technology

GPU:

NVIDIA RTX™ 4000 SFF Ada
Generation

ARBEITSSPEICHER:

64 GB DDR4

FESTPLATTEN:

2× 1.92 TB NVMe DC-Edition

BANDBREITE:

1 GBit/s-Port

BANDBREITE
GARANTIIERT:

1 GBit/s

TRAFFIC:

Unbegrenzt *

VERFÜGBARE
STANDORTE:

 FSN 1

pro Monat

234,00 €

pro Stunde

0,3750 €

einmalig Setup

+ 114,00 €

exkl. USt.


 **Konfigurieren**

Teurer Spaß: 278 Euro kostet der GEX44 inklusive Umsatzsteuer. Dafür steckt im Server eine Workstation-GPU von Nvidia.

Auf die Probe

Im Einrichtungsdialog haben wir uns für den Test für Ubuntu Server 24.04 LTS entschieden, zur Wahl standen auch die Linux-Distributionen AlmaLinux, CentOS, Debian und Rocky Linux. Wer auf dem Server GPU-intensive Windows-Software betreiben will, muss 58 Euro monatlich für eine Lizenz von Windows Server 2025 Standard berappen. Der GEX44 läuft im Hetzner-Rechenzentrum in Falkenstein, also in Deutschland. Das ist relevant, wenn man zum Beispiel personenbezogene Daten verarbeiten möchte.

Nach der Bestellung muss man sich etwas gedulden, der Auftrag wird zuerst geprüft – unser Testserver war nach wenigen Stunden einsatzbereit. Unter Linux begrüßt der Server dann mit einer nackten SSH-Sitzung. Wie man die nötigen Nvidia-Treiber und weiteres Zubehör installiert, um KI-Modelle zu betreiben, haben wir in der **Anleitung zu OpenWebUI und Ollama ausführlich beschrieben [16]**.



[17]

Die Kosten

Die zentrale Frage, unabhängig von der konkreten Anwendung: Lohnt sich die Servermiete im Vergleich zum Kauf eigener Hardware? Dafür ist ein Blick auf Anschaffungs- und Betriebskosten nötig.

Die Grafikkarte vom Typ RTX 4000 SFF Ada Generation kostet in der Anschaffung etwa 1600 Euro (alle Preise inklusive Umsatzsteuer). Bei ihr handelt es sich um gestandene Server- oder Workstationhardware und nicht etwa um eine umfunktionierte Spielegrafikkarte. Die weitere Ausstattung unseres Testservers haben wir mit dem Linux-Bordmittel dmidecode ausgelesen.

Der verbaute Intel Core i5-13500 (seit 2023 auf dem Markt) liegt in der Anschaffung bei knapp 300 Euro. Er hat sechs Performance- und acht Effizienz-Kerne, die bei unseren Tests mit Ollama nicht ins Schwitzen kamen. Während die Grafikkarte ordentlich ackern musste, gab es für die CPU wenig Arbeit zu verrichten.

Das Mainboard Prime B760M-A D4 schlägt aktuell mit rund 130 Euro zu Buche, dabei handelt es sich nicht um ausgewiesene Server- oder Workstation-Hardware. Die beiden 32-GB-Byte-RAM-Riegel (DDR4 ohne ECC) vom Typ **Samsung M378A4G43AB2-CWE** [18] kosten zusammen 360 Euro. Auch den RAM haben wir bewusst nicht beansprucht, sondern KI-Modelle ausgewählt, die inklusive Key-Value-Store vollständig in den VRAM der GPU passen – sogenanntes Offloading in den RAM macht die Antworten langsam.


Teuer sind aktuell die beiden verbauten 1,92-TByte-NVMe-SSDs von Micron. Bei den SSDs hat Hetzner oben ins Regal gegriffen, es handelt sich um Datacenter-SSDs vom Typ Micron 7500 Pro, die im Handel zusammen satte 3000 Euro kosten – fast doppelt so viel wie die Grafikkarte.

Zusammengerechnet stecken im GEX44 Komponenten im Wert von rund 5400 Euro – mit Gehäuse und Netzteil kann man 6000 Euro Anschaffungskosten für die weiteren Rechnungen ansetzen.

Möchte man abwägen, ob Kaufen günstiger ist als Mieten, muss man die Mietkosten bei Hetzner gegenrechnen: 278 Euro kostet der Server im Monat inklusive Umsatzsteuer (45 Cent pro Stunde), die Einrichtung einmalig 135 Euro. Hochgerechnet heißt das: Nach knapp 21 Monaten Dauerbetrieb hätte man Hetzner in etwa die Anschaffungskosten für die Hardware bezahlt. Grundsätzlich kann man den Server jederzeit kündigen, also auch mitten im Monat. Dann zahlt man nur für die Stunden, in denen er gelaufen ist. Die Einrichtungskosten verhindern jedoch, dass man Kosten spart, indem man die Installation eines LLM-Servers per Skript komplett automatisiert und ihn beispielsweise nach Feierabend löscht und immer am Morgen neu einrichtet.

In der Kostenrechnung fehlen bisher die Betriebskosten: Einerseits bekommt man zum Server eine 1-Gbit/s-Internetverbindung ohne Volumenbeschränkung und während der Laufzeit auch eine IPv4-Adresse, über die man den Server aus dem Internet erreicht. Eine schnelle Internetverbindung weiß man zu schätzen, wenn man verschiedene Sprachmodelle zum Testen herunterlädt. In den Speicher der Grafikkarte passen 20 GByte, passende Modelle liegen also in dieser Größenordnung. Dem Server hätten auch 10 GBit/s oder 2,5 GBit/s nicht geschadet und technisch wäre auch mehr möglich: Das verbaute Mainboard hat Ethernet-Anschlüsse mit 2,5 GBit/s, die nicht voll ausgenutzt werden.

Großer Kostenfaktor beim Betrieb ist die elektrische Energie: Hetzner gibt im Datenblatt an, dass die GEX44-Maschine im Leerlauf 33 Watt Strom konsumiert, in der Spitze 187 Watt. Die Grafikkarte allein kann in der Spitze 70 Watt umsetzen – so steht es in ihrem Datenblatt und so konnten wir es auch unter Last mit dem Werkzeug nvidia-smi messen. Sobald ein Sprachmodell antwortet, schnell die Last während der Bedenkzeit auf den Höchstwert 70 Watt.



Wenn das Modell denkt, füllt sich der Video-RAM und die Leistungsaufnahme der GPU steigt auf bis zu 70 Watt.

Würde man die Maschine rund um die Uhr auslasten, könnte man bis zu 135 kWh Strom im Monat verheizen. Bei 30 Cent pro Kilowattstunde entspricht das bis zu 40 Euro. Im Rechenzentrum kommen dazu noch Kosten, um die Wärme herauszukühlen. Berücksichtigt man die Betriebskosten mit knapp 50 Euro im Monat, verschiebt sich der Zeitpunkt, ab dem der Serverkauf günstiger ist als die Miete bei Hetzner: Ab etwa 26 Monaten Dauerbetrieb ist man mit einem Kauf günstiger dran (Kapitalkosten nicht mitgerechnet).

Nicht perfekter Zuschnitt

Der Mietpreis, den Hetzner aufruft, ist kaufmännisch nachvollziehbar und das Angebot lohnt sich für Firmen, die sich an den Betrieb selbstgehosteter KI herantasten wollen. Die Wahl der Hardware des GEX44 ist aber aus zwei Gründen für den KI-Betrieb nicht ideal: Auf der einen Seite ist da die RTX 4000 mit 20 GByte Video-RAM. Die war 2024, als Hetzner den Server auf den Markt gebracht hat, eine gute Wahl und die Karte lieferte im Test schnelle Antworten mit leistungsstarken Modellen: Das Modell Qwen 3.6 mit 27 Milliarden Parametern lieferte in der Quantisierung Q4_K_M Antworten mit 18 Token pro Sekunde. Schnellstes Modell im Test war Gemma 4 von Google in der Variante E4B. Das antwortete mit 65 Token pro Sekunde.

Viele offene Modelle, oder genauer die **quantisierten Varianten [19]**, sind heute aber auf 24 GByte Speicher ausgelegt, weil das eine gängige Größe für (Gaming-)Grafikkarten ist. Bei der Quantisierung werden die Gewichte des neuronalen Netzes in weniger genauen Variablen gespeichert, damit die Modelle in bezahlbaren Speicher passen.

Ein Qwen 3.6 mit 27 Milliarden Parametern passt in 20 GByte nur in der Quantisierung Q4_K_M, bei 24 GByte wäre die bessere Qualitätsstufe Q5_K_M möglich. Nvidias Nemotron 3 Nano mit 30 Milliarden Parametern passt ganz knapp nicht in der Quantisierung Q4_K_M – das ist alles kein Beinbruch, beim Experimentieren mit Modellen aber etwas frustrierend, weil eine RTX 3090 (ab 1700 €) für Spieler mehr VRAM hat als die Workstation-Karte.

Aus finanzieller Sicht ärgerlicher ist die zweite Entscheidung des Hosters: Die beiden Datacenter-SSDs mit je 1,92 TByte sind der größte Kostenfaktor (in der Anschaffung doppelt so teuer wie die GPU). Sie treiben den Mietpreis nach oben und leider kann man sie bei der Bestellung nicht kleiner konfigurieren. Die beiden Platten sind als RAID1 konfiguriert, die Daten werden gespiegelt; es stehen also 1,92 TByte Platz zur Verfügung. In dem von uns getesteten Szenario, in dem man eine Handvoll Module herunterlädt, die jeweils etwas kleiner als 20 GByte sind, bleiben die teuren Platten ziemlich leer. 500 GByte hätten für diese Anwendung ganz locker ausgereicht.

Fazit und Tabelle

Hetzners GEX44 ist ein passendes Angebot für Firmen, die erste Schritte mit selbst betriebener KI gehen wollen, für private Enthusiasten sind die monatlichen Kosten zu hoch. Wie fair Hetzner die Preise berechnet hat, zeigt ein Blick auf den Wettbewerb: **Clouddienstleister Akamai [20]** beispielsweise hat einen weitgehend vergleichbaren Server (mit Standort in Europa) mit der gleichen RTX 4000 Ada Generation und 64 GByte RAM im Sortiment. Dort kostet die Stunde 0,96 US-

Dollar, umgerechnet und mit Umsatzsteuer knapp 1 Euro – das entspricht über 720 Euro im Monat und Traffic aus dem und ins Internet wird anders als bei Hetzner separat abgerechnet.

Mit Konfigurationsmöglichkeiten könnte Hetzner den GEX44 noch attraktiver gestalten: Schnellere Internetanbindung oder kleinere SSDs wären wünschenswerte Optionen.

Tabelle

Hetzner GEX44: Daten und Testergebnisse

getestete Konfiguration	GEX44
Verfügbare Betriebssysteme	AlmaLinux, CentOS, Debian, openSUSE, Rocky Linux, Ubuntu, Windows Server (kostenpflichtig)
Ausstattung	
Prozessor	Intel Core i5-13500
Hauptspeicher / SSD	64 GByte DDR4 / 2 × 1,92 TByte
GPU	Nvidia RTX 4000 SFF Ada Generation
Antwortgeschwindigkeit von LLMs ¹	
Gemma 4 E4B	65 Token/s
Qwen 3.6 27B Q4_K_M	18 Token/s
Mistral 7B	55 Token/s
Preis	
Preis pro Monat	280 €
Preis pro Stunde	0,45 €
Einrichtung	136 €

¹getestet mit Ollama
Tabelle: Leia Marie Göbser / heise medien • Quelle: Jan Mahn / heise medien

(jam [21])

URL dieses Artikels:

<https://www.heise.de/-11360231>

- Links in diesem Artikel:
- [1] <https://www.hetzner.com/de/dedicated-rootserver/matrix-gpu/>

[2] <https://www.nvidia.com/de-de/products/workstations/professional-desktop-gpus/rtx-pro-6000-max-q/>

[3] <https://www.nvidia.com/de-de/products/workstations/rtx-4000-sff/>

- [4] <https://www.heise.de/tests/GPU-Server-fuer-KI-Selfhosting-Hetzner-GEX44-im-Test-11360231.html>
- [5] <https://www.heise.de/ratgeber/Sprachmodelle-mit-Open-WebUI-LLM-Server-fuer-kleine-Teams-selbst-hosten-11333185.html>
- [6] <https://www.heise.de/tests/Kompakte-KI-Workstation-Gigabyte-AI-Top-Atom-alias-Nvidia-DGX-Spark-im-Test-10867427.html>
- [7] <https://www.heise.de/news/Framework-Desktop-im-Test-Das-KI-Monster-10515051.html>
- [8] <https://www.heise.de/news/Lokale-KI-Modelle-sind-jetzt-brauchbar-und-auf-dieser-Hardware-laufen-sie-10864518.html>
- [9] <https://www.heise.de/hintergrund/Sprachmodelle-lokal-betreiben-Fuenf-Tools-vorgestellt-10312843.html>
- [10] <https://www.heise.de/hintergrund/Uebersicht-ueber-kleine-KI-Modelle-die-sich-fuer-den-lokalen-Betrieb-eignen-10306979.html>
- [11] <https://www.heise.de/tests/HP-Z2-Mini-G1a-Kompakte-Workstation-mit-starkem-Kombiprozessor-im-Test-10456555.html>
- [12] <https://www.heise.de/tests/Apple-Mac-mini-mit-M4-und-M4-Pro-im-Test-10212858.html>
- [13] <https://www.heise.de/tests/Mac-Studio-M3-Ultra-Apples-schnellster-Mehrkerner-im-Test-10311863.html>
- [14] <https://www.heise.de/ratgeber/Sprachmodelle-mit-Open-WebUI-LLM-Server-fuer-kleine-Teams-selbst-hosten-11333185.html>
- [15] <https://www.heise.de/hintergrund/Warum-Big-Tech-Konzerne-ihre-KI-Modelle-oeffnen-ein-Interview-11318823.html>
- [16] <https://www.heise.de/ratgeber/Sprachmodelle-mit-Open-WebUI-LLM-Server-fuer-kleine-Teams-selbst-hosten-11333185.html>
- [17] <https://www.heise.de/ct>
- [18] <https://geizhals.de/samsung-dimm-32gb-m378a4g43ab2-cwe-a2328262.html>
- [19] <https://www.heise.de/hintergrund/Wie-man-riesige-Sprachmodelle-auf-praxistaugliche-Masse-schrumpft-10286307.html>
- [20] <https://www.akamai.com/cloud/pricing/europe#tabs-47cab9f094-item-31da8513ae-tab>
- [21] <mailto:jam@ct.de>

Copyright © 2026 Heise Medien